

Theory on AI Safety First

I dag er der meget hype omkring AI-sikkerhed og governance. På trods af rig debat er der endnu ingen, der er kommet med konkrete forslag til løsninger. Mange siger, hvad man *burde* gøre — men meget få bygger noget, der faktisk adresserer problemerne.

Dette dokument er ikke “LØSNINGEN”, men et konkret bud på, hvordan man kan løse centrale sikkerhedsudfordringer i AI-systemer.

En stor del af problematikken kan løses ved at tænke i en anden rækkefølge end den, der traditionelt bruges:

1. **Zero-trust**
2. **Safety first**
3. **Scenarie-tænkning** (alle tænkelige og utænkelige scenarier)
4. **Kendte og ukendte angrebsflader**
5. **Fast og urokkelig definition af hvad AI må og ikke må**
6. **Design sikkerhedsarkitekturen omkring disse regler**
7. **Hardware-rooted sikkerhed** (fx SE050 secure element)
8. **Systemet må ikke kunne starte uden signeret sikkerhedsmanifest**
9. **Grundregel: Hvis du kan forestille dig det, kan andre også — og nogen vil forsøge det**

★ Case Study: Elvi som praktisk implementering af Safety-First AI

For at illustrere, hvordan ovenstående principper kan omsættes til praksis, følger her en case-beskrivelse af Elvi — et eksperiment i at bygge AI ud fra en **safety-first tilgang**, hvor arkitekturen er færdig, før intelligensen overhovedet får lov at eksistere.

Elvi er ikke “et produkt”. Hun er et **bevis på, at sikkerhed kan bygges før AI**.

1. Zero-Trust implementeret i praksis

Elvi antager ikke, at AI er stabil, godartet eller selvkorrigerende. Zero-trust er implementeret gennem:

- hardware-rooted identitet
- signeret sikkerhedsmanifest
- ingen opstart uden verificeret sikkerhed
- ingen mulighed for at ændre regler efter opstart

Dette viser, hvordan **zero-trust** kan fungere som fundament, ikke som et lag ovenpå.

2. Safety-First arkitektur før AI-laget

Elvi følger princippet:

Build safety first — AI last.

Det betyder:

- adfærdsgrænser defineres før modelvalg
- etik er arkitektur, ikke policy
- AI-delen er “gæst” i et sikkert system
- sikkerhed er fysisk forankret

Dette demonstrerer, at sikkerhed kan være *første designlag*.

3. Scenarie-tænkning som designmetode

Elvi’s arkitektur bygger på en systematisk gennemgang af:

- fejlscenarier
- misbrugsscenarier
- menneskelig manipulation
- sociale edge-cases
- tekniske angreb

Grundreglen:

Hvis du kan forestille dig det, kan andre også — og nogen vil forsøge det.

Dette er **scenario-driven safety** i praksis.

4. Kendte og ukendte angrebsflader

Elvi adresserer både:

- fysiske angreb
- software-angreb
- social engineering
- sensor-spoofing
- menneskelig påvirkning
- uforudsigelig adfærd

Dette viser, hvordan man kan bygge AI, der er robust mod både tekniske og menneskelige angreb.

5. Urokkelige regler og deterministisk adfærd

Elvi kan ikke:

- ændre sine egne regler
- forhandle grænser

- optimere mod nye mål
- udvikle agentiske tendenser
- manipulere
- eskalere

Dette er **non-agentic design** implementeret i praksis.

6. Hardware-rooted sikkerhed (SE050)

Elvi's sikkerhed er fysisk forankret:

- secure element som root of trust
- signeret manifest
- ingen opstart uden verificeret sikkerhed
- ingen mulighed for at omgå begrænsninger

Dette viser, hvordan **hardware-rooted constraints** kan gøre AI-sikkerhed umulig at ignorere.

7. Fysisk forankring som sikkerhedslag

Elvi er en fysisk enhed, ikke en cloud-AI. Det giver:

- air-gapped trust
- kontrolleret sensorinput
- menneskelig kontrol over miljøet

Dette er **physical-grounded AI safety**.

Hvorfor Elvi understøtter dette dokument

Elvi fungerer som et konkret bevis på, at:

- sikkerhed kan bygges før AI
- arkitektur kan forhindre farlig adfærd
- non-agentic design er muligt
- hardware-rooted sikkerhed virker
- deterministiske grænser kan håndhæves
- misuse-resistance kan designes, ikke patches

Elvi er ikke "løsningen", men et **praktisk eksempel** på, hvordan principperne i dette dokument kan omsættes til virkelighed.

Konklusion

Build safety first — AI last. AI er ikke farlig, når den er bygget rigtigt. Den er farlig, når sikkerheden kommer bagefter. Derfor skal arkitekturen være sikker, før intelligensen overhovedet får lov at starte.